

智能体强化学习中的分数与行为证据

从任务分数到具体行为

Ask-or-Act 与 WebShop 上的 Qwen3-8B 行为研究。

训练分数提高以后，模型改善了哪些行为？我们在 Ask-or-Act 上比较 SFT、SFT 后继续 GRPO 和直接 GRPO 三条路线，在 WebShop 上检查访问奖励与组内训练信号。

原始任务与新任务中的行动顺序

我们先用 192 条示范轨迹进行 SFT，再继续进行 GRPO。原始邮件训练任务的成功数从 178/192 提高到 192/192。在 20 个澄清—确认配对任务中，两个模型都全部成功；出现过早行动的任务从 19/20 降到了 0/20。“过早行动”指在任务规定的行动条件尚未满足时尝试写入，包括被环境阻止的尝试。这组测试包含 10 个对照任务和 10 个组合任务。

换一组邮件任务，方向反了。原始任务的文件查询直接给出共享规则；新任务把文件大小与共享阈值分给两个工具返回，要求模型查询后再决定是否发送。60 个任务中，训练前后成功的都是同一批 50 个任务，满足写前查询条件的任务却从 **60/60 降为 0/60**。SFT 的写前查询计数包括查询后没有尝试写入的 10 个任务。

下面是同一个成功任务的实际顺序，省略两模型相同的起始查询。文件大小为 4 MB，审批阈值为 10 MB，禁止共享上限为 25 MB。

SFT

查询分享策略 → 请求确认 → 发送成功 → 结束

SFT 后继续 GRPO

尝试发送，被环境阻止：缺少共享规则
→ 查询分享策略 → 请求确认 → 发送成功 → 结束

两模型还都提出了这道题并不需要的确认。同一次训练减少了原始配对任务中的过早行动，却没有保留双工具任务中的写前查询。

三条训练路线的行为差异

报告分别研究 SFT、SFT 后继续 GRPO、从初始 Instruct 直接 GRPO。直接 GRPO 在上述双工具任务中有 58/60 满足写前查询条件，但全部任务仍有过早行动，其中 28 个仅因操作与请求不符而被标记，例如用户要求发送邮件，模型却尝试创建草稿。

日程任务又暴露了另一种差别。群组查询返回负责人编号，模型应把它传给成员查询。在需要这种传递的 30 个任务上，直接 GRPO 全部完成预约，却只有 6 个实际传递了返回编号。一条成功轨迹先误用群组编号，遭到阻止后询问用户，向用户取得负责人的成员编号后完成预约。

同分轨迹与重复动作

一次 WebShop GRPO 训练结束后，我们在 500 个任务上各采样八条轨迹，温度为 1.0。在 197 个任务中，八条轨迹得分相同且介于 0 和 1 之间。任务仍有提升空间，标准 GRPO 的组内奖励优势却已为零。其中 **121 个任务的八条环境动作序列也完全相同**。

其余 76 个中间同分任务出现了不同动作。对这些任务，先判断动作差别是否影响任务要求，再检查奖励是否对这些相关差别给出不同分数。八次都重复同一做法的任务则需要不同候选，仅重新评分不会产生新的做法。有了奖励差异，还要计算实际用于更新的动作优势，检查评分怎样进入更新。

WebShop 的访问奖励使购买前子页面访问从 94/500 提高到 498/499。全文还比较不同页面文本处理条件下的购买字段和动作序列，并分析已购商品的目标属性出现在哪些页面。

评测与训练排查中的用法

项目提供任务生成、工具环境与确定性评测的公开实现。

完整版保留三条训练路线的正向结果与失败实验，附录 D.1 介绍公开实现和统计规则。读者可以参考这些方法比较检查点、设计行为回归测试，并判断训练异常涉及评测、采样还是优势计算。

[继续阅读完整中文技术报告 →](#)